WYDZIAŁ ELEKTRONIKI
I TECHNIK INFORMACYJNYCH

Rozproszone systemy operacyjne

Szczegółowa koncepcja rozwiązania

Autorzy:

Tomasz Adamiec
Piotr Cebulski
Marek Kowalski
Mateusz Rosiewicz
Paweł Sokołowski
Marcin Wnuk

Warszawa, 2013

Interfejs programu mongod

Celem projektu jest zaimplementowanie bazy danych działających zgodnie z interfejsem MongoDb. Ważnym jest więc zapoznanie się z tym interfejsem i przeprowadzenie wszelkich operacji bazodanowych w oparciu o jego komendy.

Programem odpowiedzialnym za wykonywanie operacji bazodanowych jest mongod. Mongod jest aplikacją nasłuchującą na określonym porcie (domyślnie jest to 27017, ale można go zmienić za pomocą odpowiedniego parametru wywołania programu). Komunikuje się on z klientami za pomocą odpowiednio zdefiniowanego protokołu. Wszelkie typy używane w komunikatach są zgodne z formatem BSON[1]. I tak łańcuchy znaków są typu odpowiadającego **cstring** z języka C (kodowane w UTF-8, zakończone zerem), a porządkiem bajtów we wszystkich innych typach jest **little-endian**. W skład tego protokołu wchodzi obecnie 8 różnych rodzajów wiadomości.

Każdy komunikat przesyłany z i wysyłany do **mongod** rozpoczyna się od następującego nagłówka:

```
struct MsgHeader {
    int32   messageLength;
    int32   requestID;
    int32   responseTo;
    int32   opCode;
}
```

Składa się on z czterech czterobajtowych liczb typu integer. Pierwsza z nich określa długość całej wiadomości (a więc 16 bajtów nagłówka powiększone o długość komunikatu specyficzną dla jego typu). Kolejną jest **requestID –** jest to identyfikator wiadomości, nadawany przez **mongod** lub też przez jego klienta. Jeżeli wiadomość jest odpowiedzią serwera bazy danych ta sama wartość umieszczana jest w **responseTo**. W pozostałych przypadkach pole to przyjmuje wartość 0. Ostatnim z elementów nagłówka jest **opCode** – jest to wartość określająca typ wiadomości. Może ona przyjmować następujące wartości:

opCode	Wartość	Komentarz
OP_REPLY	1	Odpowiedź na rządanie klienta. Jako jedyny typ posiada ostawioną wartość responseTo.
OP_MSG	1000	Ogólna wiadomość. Po nagłówku występuje ciąg znaków
OP_UPDATE	2001	Aktualizacja dokumentu
OP_INSERT	2002	Wstawienie nowego dokumentu
RESERVED	2003	Obecnie nieużywana
OP_QUERY	2004	Zapytanie
OP_GET_MORE	2005	Pobiera więcej danych z zapytania
OP_DELETE	2006	Usunięcie dokumentu
OP_KILL_CURSORS	2007	Zamknięcie aktualnie otwartego kursora w bazie danych.

[1] : http://bsonspec.org/#/specification

Przykład: OP_INSERT

Zostanie teraz zaprezentowany jeden z typów komunikatów: **OP_INSERT**[2]. Struktura takiego komunikatu wygląda następująco:

```
struct {
    MsgHeader header;
    int32 flags;
    cstring fullCollectionName;
    document* documents;
}
```

Pierwszym polem **header** jest wcześniej omawiany podstawowy, wspólny dla wszystkich wiadomości nagłówek. Następne pole **flags** jest wektorem bitowym o długości 4 bajtów określającym opcje operacji wstawiania. Aktualnie można ustawić tylko jedną flagę (pierwszy bit) **ContinueOnError –** określa ona czy kontynuować operację wstawiania dokumentów, gdy nie powiodła się ona dla jednego z nich. Kolejne pole **fullCollectionName** zawiera pełną nazwę kolekcji do której wstawiane są dokumenty. Jest to łańcuch znaków typu **cstring**. Ostatnie pole **documents –** zawiera kolekcję wstawianych dokumentów, zakodowanych zgodnie ze standardem BSON.

Zostanie teraz zaprezentowany przykład przedstawiający prostą wiadomość wstawienia dokumentu. Wywołania z powłoki Mongo polecenia:

```
db.entites.insert({Name: „Tom”})
```

Powoduje wysłania następującego ciągu bajtów (każdy z bajtów zapisany jest szesnastkowo):

```
46-00-00-00-04-00-00-00-00-00-00-00-D2-07-00-00-00-00-00-00-74-65-73-74-2E-
65-6E-74-69-74-69-65-73-00-24-00-00-00-07-5F-69-64-00-51-75-A7-20-41-B6-76-
09-20-E2-9A-08-02-4E-61-6D-65-00-04-00-00-00-54-6F-6D-00-00
```

Pierwsze cztery czwórki bajtów reprezentują nagłówek. 46-00-00-00 = 70 jest długością wiadomości. 04-00-00-00 = 4 jest identyfikatorem wiadomości. Kolejne cztery bajty: 00-00-00-00 = 0 zgodnie z protokołem przyjmują wartość 0, gdyż nie jest to odpowiedź serwera. Ostatnie cztery bajty nagłówka przyjmują wartość: D2-07-00-00 = 2002; wartość ta także jest zgodna z oczekiwaniami – odpowiada on typowi komunikatu: **OP_INSERT**. Dalsza część wiadomości odpowiada specyficznym polom dla operacji wstawiania dokumentu. **Flags** przyjmuję wartość 00-00-00-00 = 0, a więc żadna z flag nie została ustawiona. Kolejnym elementem komunikatu jest zakodowana pełna nazwa kolekcji: 74-65-73-74-2E-65-6E-74-69-74-69-65-73-00 = „test.entities”. Pozostałe bajty: 24-00-00-00-07-5F-69-64-00-51-75-A7-20-41-B6-76-09-20-E2-9A-08-02-4E-61-6D-65-00-04-00-00-00-54-6F-6D-00-00 reprezentują dokument w postaci BSON.

Interfejs programu mongos

1.1Czym jest mongos

Mongos jest to usługą swoistego routingu dla MongoDB. Usługa ta działa na warstwie aplikacji oraz określa ona lokalizacje dla danych w klastrze. W celu lepszego zobrazowania problem przedstawiony jest na ilustracji zamieszczonej poniżej.

[2] Po dokładny opis reszty odsyłam do: http://docs.mongodb.org/meta-driver/latest/legacy/mongodb-wire-protocol/.

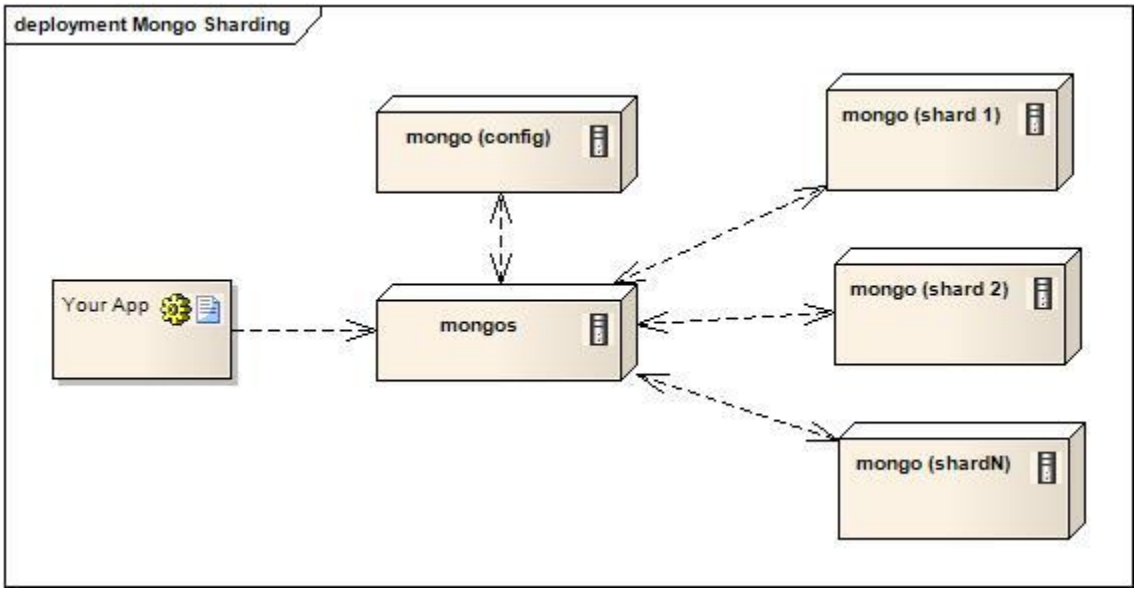

1.2Uruchamianie mongos

Po poprawnym zainstalowaniu i uruchomieniu MongoDB można uruchomić usługę mongos. Jednak by to zrobić należy zdefiniować ścieżki dostępu przedstawione poniżej:

```
> sudo mkdir -p /db/data/config
> sudo mkdir -p /db/data/shard1
> sudo mkdir -p /db/data/shard2
```

Pierwsza z powyższych komend wskazuje na położenie serwera z konfiguracją z której będzie korzystał mongos. Pozostałe komendy utworzą instancję dla shardingu.

Kolejnym krokiem jest uruchomienie serwera konfiguracyjnego:

```
> sudo mongod --dbpath "/db/data/config" --port 10381 –configsvr
```

Powyższa komenda utworzy i uruchomi demona konfiguracyjnego MongoDB. W tym przypadku będzie to przykładowo port 10381, parametr configsvr pozwoli MongoDB zidentyfikować instancję jako serwer konfiguracyjny.

Kiedy powyższe kroki zostaną wykonane można uruchomić usługę mongos komendą:

```
> sudo mongos --configdb localhost:10381 --port 10382 --chunkSize 1
```

Komenda ta utworzyła usługę mongos która korzysta z serwera konfiguracyjnego configdb oraz nasłuchuje na porcie z numerem 10382. chunkSize określa maksymalną wielkość danych wyrażoną w megabajtach.

Kolejnym krokiem jest utworzenie shard boxes zawierających nasze dane.

```
> sudo mongod --port 10383 --dbpath /db/data/shard1 --shardsvr
> sudo mongod --port 10384 --dbpath /db/data/shard2 –shardsvr
```

Powyższa komenda utworzyła dwie instancję shardów dla MongoDB. Obie instancję otrzymały unikalne numery portów oraz zostały przypisane do flagi shardsvr.

Kolejnym krokiem jest dodanie shard servers do mongos.

```
> mongo localhost:100382
> use admin
> db.runCommand({addshard: "localhost:10383", allowLocal: true})
> db.runCommand({addshard: "localhost:10384", allowLocal: true})
```

Pierwsza z komend łączy instancję mongos. Druga komenda przełącza w tryb admin w celu możliwości wykonania kolejnych komend. Kolejne komendy dodają shardy w raz z określeniem ich portów. W celu dodania większej ilość shardów po prostu należy wywołać komendę wielokrotnie z uwzględnieniem unikalnego numeru portu dla poszczególnych shardów.

Po wykonaniu powyższych kroków środowisko gotowe jest do przyjmowania danych.

1.3Komendy

`--help, -h`

Zwraca podstawową pomoc.

`--version`

Pokazuje wersje mongod.

`--config <filename>, -f <filename>`

Określa plik konfiguracyjny który może zostać użyty w celu załadowania ustawień dla mongos

`--verbose, -v`

Zwieksza ilość sprawozdawczości wewnętrznej dla standardowego wyjścia lub w pliku z logami określonego w --logpath.

`--quiet`

Uruchamia instancję mongos w trybie quite, który ogranicza ruch generowany na wyjściu.

`--port <port>`

Określa port TCP dla mongos na którym jest prowadzony nasłuch dla klientów, którzy się łączą. Domyślnym portem jest port numer 27017.

`--bind_ip <ip address>`

Określa adres IP interfejsu na którym mongos będzie nasłuchiwał połączeń. Domyślnie mongos nasłuchuje na wszystkich interfejsach. Można to zmienić, jednak podczas dodawania nowych interfejsów należy upewnić się że zostały przeprowadzone kroki mające na celu zapewnienie bezpieczeństwa dla integralności bazy danych.

`--maxConns <number>`

Określa maksymalną ilość jednoczesnych połączeń, które zostaną przyjęte przez mongos. Ustawienie to nie ma wpływu jeśli wartość tego parametru jest wyższa niż systemu operacyjnego na którym uruchomiony jest mongos dla maksymalnego progu śledzenia połączeń. Wartość nie może być większa niż 20000.

`--objcheck`

Wymusza na mongos sprawdzenie poprawności wszystkich zapytań otrzymywanych od klientów. Chroni przed wprowadzaniem niepoprawnych obiektów do bazy danych. Opcja ta ma wpływ na wydajność i jest domyślnie wyłączona.

`--logpath`

Określa ścieżkę do pliku z logami

`--logappend`

Zapisuje logi w dzienniku na końcu pliku nie nadpisując zawartości po restarcie mongos.

`--syslog`

Wysyła wszystkie logi do systemu Syslog.

`--pidfilepath <path>`

Określa położenie pliku w którym składowane są informację na temat „PID”, id procesow

`--keyFile <file>`

Określa ścieżkę do pliku w którym przechowywany jest klucz w celu autentykacji połączenia pomiędzy mongos, a klastrami shardów.

`--nounixsocke`

Wyłącza nasłuch na socketach UNIX.

`--unixSocketPrefix <path>`

Określa ścieżkę do socketa UNIX

`--configdb <config1>,<config2><:port>,<config3>`

Określa konfigurację bazy danych.

`--test`

Opcja ta wykonywania wewnętrznych testów jednostkowych.

`--upgrade`

Opcja ta aktualizuje meta dane wykorzystywane przez konfigurację bazy danych.

`--ipv6`

Uruchamia wsparcie dla IPv6. Domyśle funkcjonalność ta jest wyłączona.

`--jsonp`

Zezwala JSONP na dostęp poprzez interfejs http.

`--noscripting`

Wyłącza silnik skryptowy.

`--nohttpinterface`

Wyłącza interfejs http

`--localThreshold`

Wpływa na logikę działania mongos podczas wyboru członków replikacji

`--noAutoSplit`

Zapobiega automatycznemu wstawiania meta danych do kolekcji podczas procesu shardingu.

Mongos

W bazie składającej się z klastra shardów, na każdym z serwerów uruchomiona jest instancja programu mongos. Program ten pośredniczy w komunikacji bazy mongod, z klastrem shardów. Spełnia on przy tym dwie podstawowe funkcje: kieruje żądania (zapis i odczyt) do odpowiedniego shardu – *query routing* oraz równoważy obciążenie wszystkich shardów - *balancer*. Mongos śledzi rozłożenie danych w bazie zbierając informację z serwerów konfiguracyjnych.

Balancer

Balancer to wykonujący się w tle proces, który ma na celu utrzymanie takiej samej liczby kawałków bazy na każdym serwerze należącym do klastra shardów. Każdy mongos ma uruchomionego balancera, ale tylko jeden (na jednym z serwerów) jest aktywny w danej chwili. Aby balancery nie działały jednocześnie używany jest mechanizm *DistributedLock.* Gdy któryś z serwerów dostaje sygnał zniesienia blokady, wykonuje on rundę balancera. W jednej rundzie następuje stwierdzenie czy występuje nierówność w obciążeniu serwerów i w razie potrzeby wysyłane jest żądanie przeniesienia co najwyżej jednego kawałka (*chunk*).

Klasy Balancera

Mechanizm balancera posiada dwa pliki nagłówkowe \mongo-master\src\mongo\s\balance.h i \mongo-master\src\mongo\s\balancer_policy.h. Zdefiniowane są w nich klasy `Balancer` i `BalancerPolicy`, a także klika klas pomocniczych.

1.4 Balancer

```
class Balancer : public BackgroundJob
{
```

```
        typedef MigrateInfo CandidateChunk;
        typedef shared_ptr<CandidateChunk> CandidateChunkPtr;

        int _balancedLastTime;

        scoped_ptr<BalancerPolicy> _policy;

        bool _init();

        void _doBalanceRound( DBClientBase& conn, vector<CandidateChunkPtr>*
                              candidateChunks );

        int _moveChunks(const vector<CandidateChunkPtr>* candidateChunks,
                        bool secondaryThrottle,
                        bool waitForDelete);

        void _ping( DBClientBase& conn, bool waiting = false );

        bool _checkOIDs();
};
```

`_balancedLastTime` – Liczba ostatnio przeniesionych kawałków.

`_policy` – Polityka, czyli wskaźnik na kawałek do przeniesienia z informacją skąd dokąd przenieść, lub NULL.

`_init()` – Łączy się z serwerem konfiguracyjnym w celu otrzymania informacji o shardach. Funkcja jest wykonywana za każdym razem, gdy rozpoczyna się runda. Właściwie, wywołuje `_checkOIDs` i sypie wyjątki.

`_doBalanceRound()` – Wykonuje rundę balancera. `conn` to adres serwera konfiguracyjnego. Najpierw sprawdza czy jest jakaś kolekcja podzielona na shardy do zbalansowania, w tym celu sprawdza czy kolekcja ma przydzielony *shardkey*. Następnie pobiera listę shardów wraz z maksymalnym możliwym obciążeniem oraz aktualnym obciążeniem. Dla każdej balansowanej kolekcji sprawdza czy jest zalecane przesunięcie czegokolwiek.

`_moveChunks()` – Przesuwa kawałki. `candidateChunks` to wektor kawałków możliwych do przesunięcia wypełniony przez funkcję `_doBalanceRound()`. Przegląda kandydatów i wybiera interesujących (??) funkcją `ChunkManager::findInterestingChunk`, następnie próbuje go przenieść `Chunk::moveAndCommit`.

`_ping()` – Odzywa się do serwera konfiguracyjnego i potwierdza, że balancer jest uruchomiony.

`_checkOIDs()` – Pobiera listę shardów i sprawdza czy wszystkie są odrębnymi procesami (czy się nazwy nie popsuły)

1.5 BalcancerPolicy

```
class BalancerPolicy
{
       static MigrateInfo* balance( const string& ns, DistributionStatus&
                                    distribution, int balancedLastTime );

    private:
        static bool _isJumbo( const BSONObj& chunk );
};
```

`balance()` – Główna funkcja, która wybiera kawałek do przeniesienia. Wskaźnik `_policy` jest uzupełniany przez tą funkcję. `ns` to namespace, a `DistributionStatus` zawiera informacje o stanie shardów w kolekcji.

Jumbo kawałek to taki którego nie da się przenieść.

1.6 ShardInfo

```
class ShardInfo
{
       void addTag( const string& tag );

       bool hasTag( const string& tag ) const;

       bool isSizeMaxed() const;

       bool isDraining() const { return _draining; }

       bool hasOpsQueued() const { return _hasOpsQueued; }

       long long getMaxSize() const { return _maxSize; }

       long long getCurrSize() const { return _currSize; }

       string getMongoVersion() const { return _mongoVersion; }

    private:
        long long _maxSize;
        long long _currSize;
        bool _draining;
        bool _hasOpsQueued;
        set<string> _tags;
        string _mongoVersion;
};
```

`isSizeMaxed()` – Czy shard jest już maksymalnie obciążony.

`isDraining()` – Czy shard jest opróżniany, jeśli tak to wiadomo, że trzeba z niego przesuwać kawałki.

`hasOpsQueued()` – Czy shard ma jakieś zdania do wykonania, zazwyczaj nie można wtedy nic z niego usuwać.

`getMaxSize()` – Maksymalny rozmiar sharda.

`getCurrSize()` – Zwraca obciążenie sharda.

1.7 MigrateInfo

```
struct MigrateInfo
{
        const string ns;
        const string to;
        const string from;
        const ChunkInfo chunk;
};
```

`ns` – Namespace

`to` – Do którego sharda przenieść kawałek.

`From` - Z którego sharda zabrać kawałek.

`Chunk` - Który kawałek przenieść.

1.8 ChunkInfo

```
struct ChunkInfo
{
        const BSONObj min;
        const BSONObj max;
}
```

`Min` – Pierwszy dokument w kawałku, inclusive.
`Max` - Ostatni dokument w kawałku, non-inclusive.

Równoważenie obciążenia shardów

Proces równoważenia obciążenia shardów rozpoczyna się w funkcji Balancer::run(). Na początku tej funkcji następuje próba inicjalizacji balancera czyli _init(). Polega ona na połączniu się z serwerem konfiguracyjnym i odebraniu najnowszych informacji o shardach (do tego służy funkcja _checkOIDs() i Shard::getAllShards()). W razie niepowodzenia, próba inicjalizacji jest ponawiana co 60 sekund.

Po udanej inicjalizacji następuje zarejestrowanie się balancera w mechanizmie blokad:

```
DistributedLock balanceLock( config , "balancer" );
```

Teraz następuje wejście do głównej pętli procesu. Wszystkie kolejne akcje, są powtarzane w każdej rundzie.

Na początku rundy wykonywana jest funkcja _ping(). Po niej następuje załadowanie najświeższych posiadanych informacji o shardach - Shard::reloadShardInfo().

Dalej balancer próbuje założyć blokadę:

```
dist_lock_try lk( &balanceLock , "doing balance round" );
```

Jeżeli nie uda mu się, to znaczy, że inny balancer jest aktywny i wątek usypiany jest na 30 lub 6 sekund (w zależności od konfiguracji). Po upłynięciu tego czasu zaczyna się nowa iteracja głównej pętli.

Jeżeli uda się założyć blokadę, rozpoczyna się właściwa runda balancera. Tworzony jest wektor kawałków możliwych do przeniesienia:

```
vector<CandidateChunkPtr> candidateChunks;
```

Jest on wypełniany przez funkcję _doBalanceRound(conn.conn() , &candidateChunks). Jeśli istnieją kawałki możliwe do przeniesienia, to jest to wykonywane za pomocą funkcji:

```
_balancedLastTime = _moveChunks(&candidateChunks, . . . );
```

Na końcu każdej rundy ponownie wykonywany jest _ping(), w celu poinformowania serwera konfiguracyjnego, że balancer jest aktywny i nie czekał.

Teraz przyjrzymy się bliżej funkcji _doBalanceRound(). Na początku tej funkcji następuje sprawdzenie czy istnieją jakiekolwiek kolekcje do zbalansowania. Polega to na odpytaniu dostępnych kolekcji o to czy posiadają klucz shardingowy (shard „key").
Dalej tworzona jest lista wszystkich shardów, dla których będzie równoważone obciążenie. Lista zawiera wszystkie potrzebne informacje (m. in. maksymalny rozmiar i aktualne obciążenie).

```
vector<Shard> allShards;
Shard::getAllShards( allShards );
```

Dla każdego sharda:

```
ShardStatus status = s.getStatus();
shardInfo[ s.getName() ] = ShardInfo( s.getMaxSize(),
                                      status.mapped(),
                                      s.isDraining(),
                                      status.hasOpsQueued(),
                                      s.tags(),
                                      status.mongoVersion() );
```

Teraz rozpoczyna się pętla, w której dla każdej kolekcji ustalana jest polityka równoważenia. Zanim jednak nastąpi ustalenie polityki, wykonywane jest przyporządkowanie kawałków bazy do shardów, w których się znajdują:

```
map< string,vector<BSONObj> > shardToChunksMap;
```

Proces ten składa się z wielu czynności sprawdzających poprawność mapowania, które nie będą tutaj omówione.

Na końcu pętli znajdywany jest kawałek do przesunięcia:

```
CandidateChunk* p = _policy->balance( ns, status, _balancedLastTime );
```

Ustalanie polityki w funkcji `BalancerPolicy::balance()`, przebiega w trzech etapach. Na początku sprawdzane jest czy któryś z shardów jest opróżniany. Jeśli istnieje taki shard, to ma on priorytet – trzeba zabrać z niego wszystkie kawałki. Nie ma tutaj znaczenia, który kawałek zostanie w tym momencie przesunięty, bo i tak trzeba zabrać wszystkie.
Jeżeli nie było żadnego opróżnianego shardu, to następuje drugi etap, w którym sprawdza się poprawność tagów każdego kawałka bazy. Tag stanowi informację o tym czy kawałek znajduje się w odpowiednim shardzie. Jeśli kawałek z niewłaściwym tagiem zostanie znaleziony, zachodzi próba przeniesienia go. Kawałek ten może być jednak duży (`_isJumbo()`) i wtedy nie może zostać przeniesiony. Może się też okazać, że nie ma sharda, do którego można by go przenieść (`getBestReceieverShard()`).
Jeżeli nie zaszła żadna z powyższych sytuacji, to wykonywany jest etap trzeci. Na początku ustalany jest próg (treshold), powyżej którego równoważenie będzie w ogóle wykonywane. Próg oznacza różnicę w ilości kawałków najbardziej i najmniej obciążonego sharda. Ustalanie skąd dokąd wykonać przesunięcie wygląda następująco:

```
string from = distribution.getMostOverloadedShard( tag );
unsigned max = distribution.numberOfChunksInShardWithTag( from, tag );
string to = distribution.getBestReceieverShard( tag );
unsigned min = distribution.numberOfChunksInShardWithTag( to, tag );
const int imbalance = max - min;
if ( imbalance < threshold ) continue;
```

Jeśli imbalance jest niemniejszy od progu to wykonywane jest przesunięcie kawałków.

```
const vector<BSONObj>& chunks = distribution.getChunks( from );
return new MigrateInfo( ns, to, from, chunks[j] );
```

Sposób ustalania wielkości progu w balancerze wygląda następująco:

```
        int threshold = 8;
        if ( balancedLastTime || distribution.totalChunks() < 20 )
            threshold = 2;
        else if ( distribution.totalChunks() < 80 )
            threshold = 4;
```